

# Utilização de Machine Learning para Irrigação de Precisão

Rogério P. dos Santos<sup>1,2</sup>, Marko Beko<sup>2</sup>, Valderi R. Q. Leithardt<sup>2,3</sup>

<sup>1</sup>Instituto Federal do Paraná – (IFPR) - Capanema - Paraná - Brasil

<sup>2</sup>COPELABS, Lusófona University, 1749-024 - Lisbon, Portugal

<sup>3</sup>VALORIZA—Research Centre for Endogenous Resource Valorization,  
Polytechnic Institute of Portalegre, 7300-555 - Portalegre, Portugal

rogerio.dosantos@ifpr.edu.br, beko.marko@ulusofona.pt

valderi@ipportalegre.pt

**Resumo.** Neste artigo, apresentamos uma proposta de tecnologia que utiliza algoritmos de Machine Learning para analisar dados de sensores e outras fontes de informação para prever necessidades de irrigação. Essa abordagem permite que os sistemas de irrigação sejam adaptados às necessidades específicas de cada local, resultando em maior eficiência e economia de água. Além disso, as aplicações de Machine Learning em tempo real permitem que os sistemas de irrigação sejam ajustados e otimizados para atender às mudanças climáticas e outras condições ambientais, resultando em uma irrigação mais eficiente e sustentável.


## 1. Introdução

A irrigação de precisão é uma abordagem de gestão que utiliza tecnologias como sensores e inteligência artificial para coletar e analisar dados sobre solo, clima e condições das plantas para otimizar a produção agrícola [Zia et al. 2021]. Aplicações de machine learning em irrigação de precisão podem incluir análise de imagens de satélite para identificar áreas de solo seco e a necessidade de irrigação, previsão do tempo para determinar quando e quanta água é necessária para as plantas, monitoramento de sensores de solo para medir a umidade do solo e identificar áreas que precisam de mais análises de dados hídricos e climáticos para prever as condições futuras e otimizar a irrigação. Essas tecnologias podem ajudar os agricultores a economizar água, aumentar a eficiência da irrigação e melhorar a qualidade da colheita [Abioye et al. 2022]. Nesse sentido, este trabalho visa apresentar um modelo de machine learning que pode ser utilizado para prever e otimizar a irrigação em plantações de lúpulo. O uso desse modelo permitirá que os agricultores tomem decisões informadas, levando a um uso mais eficiente da água, o que ajudará a reduzir os custos de produção e otimizar o rendimento. Além disso, o modelo monitorará a saúde do solo e reduzirá o risco de danos às plantas devido à seca [Tschand 2023].

## 2. Modelo Proposto

Para atingir o objetivo proposto, será essencial comparar duas técnicas diferentes de aprendizado de máquina para entender qual é mais eficaz na previsão das melhores práticas de irrigação. Por exemplo, pode-se comparar o desempenho de um modelo de regressão linear com um modelo de árvore de decisão. A primeira técnica a ser alcançada é a regressão linear. Um método que busca estabelecer a relação linear entre uma variável dependente e uma ou mais variáveis independentes. A segunda técnica a ser comparada é a árvore

de decisão. Um modelo em forma de árvore para prever saída categórica com base em variáveis de entrada. Ambos podem ser usados para prever a água necessária para o cultivo de lúpulo com base nas condições climáticas, características do solo e outros fatores. Será necessário usar computadores de alto desempenho para analisar os dados e modelos apresentados em (Figura 1). Comparando as duas técnicas, pode-se verificar qual é mais eficaz em prever as melhores práticas de irrigação e implementá-las para aumentar a produtividade e rentabilidade da plantação de lúpulo. Uma vez que o modelo preditivo esteja



**Figura 1. Modelo de Arquitetura**

pronto, ele pode gerar recomendações para o cultivo de lúpulo por referência cruzada de dados recebidos em tempo real sobre condições climáticas e características do solo e da cultura. As previsões podem criar solicitações de cultivo de lúpulo, como a quantidade de água a ser aplicada, os melhores horários para regar e outras informações relevantes. Essas recomendações podem ser enviadas aos agricultores em tempo real por meio de aplicativos ou sistemas de automação para que possam tomar decisões informadas sobre irrigação. Finalmente, como principal motivação, é essencial monitorar continuamente os dados de entrada e atualizar o modelo com frequência para garantir que as recomendações geradas sejam precisas e relevantes.

### 3. Considerações Preliminares

Como resultado preliminar, foi possível comparar e identificar um modelo que melhor se adequa às práticas de irrigação em plantações de lúpulo. Para isso, foram coletados dados sobre condições climáticas, solo, características das plantas e métodos de irrigação utilizados. Em seguida, foram realizadas sessões de treinamento. Finalmente, o modelo treinado foi aplicado a um conjunto de dados de teste para avaliar sua precisão de previsão, analisar os resultados e compará-los com as práticas atuais de irrigação e identificar a melhor para aumentar a produtividade das plantações.

### Referências

- Abioye, E. A., Hensel, O., Esau, T. J., Elijah, O., Abidin, M. S. Z., Ayobami, A. S., Yerima, O., and Nasirahmadi, A. (2022). Precision irrigation management using machine learning and digital farming solutions. *AgriEngineering*, 4(1):70–103.
- Tschand, A. (2023). Semi-supervised machine learning analysis of crop color for autonomous irrigation. *Smart Agricultural Technology*, 3:100116.
- Zia, H., Rehman, A., Harris, N. R., Fatima, S., and Khurram, M. (2021). An experimental comparison of iot-based and traditional irrigation scheduling on a flood-irrigated subtropical lemon farm. *Sensors*, 21(12):4175.